

Inference、Memory、Scheduling 与 Serving Engine：P99 慢之前，先拆开 request path

Worksheet

用固定 synthetic workload，分开 queue、prefill、decode、tool、validation、retry、memory、batching 与 fallback，不用一个平均值解释全部。

01	读者要做的决定与使用者	
02	Input、数据边界与禁止动作	
03	简单 baseline 与可接受输出	
04	固定 cases、failure 与 handoff	
05	系统部分，可以核对什么：version、test、trace 或 result	
06	用在工作上，还要讲清什么：owner、成本、风险与下一步	