

Inference、Memory、Scheduling 同 Serving Engine：P99 慢之前，先拆開條 request path

Worksheet

用固定 synthetic workload，分開 queue、prefill、decode、tool、validation、retry、memory、batching 同 fallback，唔用一個平均值解釋全部。

01	讀者要作的決定與使用者	
02	Input、資料邊界與禁止動作	
03	簡單 baseline 與可接受輸出	
04	固定 cases、failure 與 handoff	
05	系統部分，可以核對乜：version、test、trace 或 result	
06	用喺工作上，仲要講清乜：owner、成本、風險和下一步	