

Modern Attention、MoE 与 Serving：从模型名回到 workload 与 budget Worksheet

把 context length、sparse experts、prefill、decode、batching 与 P99 放回固定 workload，同时写清未知、fallback 与停止条件。

01	读者要做的决定与使用者	
02	Input、数据边界与禁止动作	
03	简单 baseline 与可接受输出	
04	固定 cases、failure 与 handoff	
05	系统部分，可以核对什么：version、test、trace 或 result	
06	用在工作上，还要讲清什么：owner、成本、风险与下一步	