

Modern Attention、MoE 同 Serving：由模型名走返去 workload 同 budget Worksheet

將 context length、sparse experts、prefill、decode、batching 同 P99 放返入固定 workload，同時寫清未知、fallback 同停止條件。

01	讀者要作的決定與使用者	
02	Input、資料邊界與禁止動作	
03	簡單 baseline 與可接受輸出	
04	固定 cases、failure 與 handoff	
05	系統部分，可以核對乜：version、test、trace 或 result	
06	用喺工作上，仲要講清乜：owner、成本、風險和下一步	