

Modern Attention、MoE 與 Serving：從模型名回到 workload 與 budget Worksheet

把 context length、sparse experts、prefill、decode、batching 與 P99 放回固定 workload，同時寫清未知、fallback 與停止條件。

01	讀者要做的決策與使用者	
02	Input、資料邊界與禁止動作	
03	簡單 baseline 與可接受輸出	
04	固定 cases、failure 與 handoff	
05	系統部分，可以核對什麼：version、test、trace 或 result	
06	用在工作上，還要講清什麼：owner、成本、風險與下一步	